

# Trabalho Interdisciplinar 6

## Sotware de Detecção de Câncer de Pulmão em Tomografias de Torax

Arthur Dias<sup>1</sup>, Bruno Pietra<sup>2</sup>, João Pedro Camargo<sup>3</sup>, Felipe Matoso<sup>4</sup>

<sup>1</sup>Instituto de Ciências Exatas e Informática  
Pontifícia Universidade Católica de Minas Gerais (PUC Minas)  
Caixa Postal 1.686 – 30535-901 – Belo Horizonte – Minas Gerais – Brasil

**Abstract.** Lung cancer is a serious type of cancer that causes approximately 422 deaths each day worldwide. In this sense, in order to combat it, an early diagnosis is a convenient requirement to increase patients' chances of survival. In this sense, the objective of the article is to document the development of an application to analyze patient chest CT scans. The accuracy of the achieved model is 84 percent and the software is currently available on AWS servers.

**Resumo.** O câncer de pulmão é um tipo grave de câncer que causa aproximadamente 422 mortes a cada dia em todo o mundo. Nesse sentido, a fim de combatê-lo, um diagnóstico precoce é um requisito conveniente para aumentar as chances de sobrevivência dos pacientes. Nesse sentido, o objetivo do artigo é documentar o desenvolvimento de uma aplicação para analisar tomografias de tórax de pacientes. A acurácia do modelo alcançado é de 84 por cento e o software, no momento, se encontra disponibilizado nos servidores da AWS.

### 1. Introdução

O câncer de pulmão é um dos tumores mais comuns e letais em todo o mundo e tem um impacto significativo na saúde pública global. A detecção precoce deste tipo de câncer é fundamental, pois a identificação precoce pode aumentar muito as chances de um tratamento bem-sucedido e de sobrevivência. No entanto, esta tarefa é muito desafiadora devido ao fato de o câncer de pulmão ser frequentemente assintomático em seus estágios iniciais e às limitações das técnicas tradicionais de diagnóstico.

Neste contexto, os desenvolvedores de aplicações de análise de imagens para detecção de câncer desempenham um papel vital. Os desenvolvimentos nas tecnologias de imagem, como a tomografia computadorizada (TC) e a ressonância magnética (MRI), juntamente com os avanços na inteligência artificial (IA) e na aprendizagem automática, proporcionam novas oportunidades para melhorar a precisão e a eficiência da identificação de tumores pulmonares.

O desenvolvimento de sistemas automatizados de detecção de câncer de pulmão envolve a criação de algoritmos que possam analisar com precisão e rapidez grandes quantidades de dados de imagem. Esses algoritmos precisam ser treinados para identificar padrões e anormalidades que possam indicar a presença de malignidade. Construir um banco de dados robusto e diversificado de imagens é fundamental para treinar esses

modelos de IA, para que possam aprender a diferenciar entre tecido pulmonar saudável e áreas que requerem atenção médica.

No entanto, esta tarefa não está isenta de desafios. Um dos grandes obstáculos é a variação na qualidade e resolução da imagem, além da necessidade de diferenciação entre lesões benignas e malignas, que podem ser muito sutis. A precisão do diagnóstico auxiliado por computador depende da qualidade dos dados de treinamento e da capacidade do algoritmo de se adaptar às diferentes características da imagem.

Além disso, a validação destes sistemas requer um processo de testes rigoroso para garantir que funcionam adequadamente em ambientes clínicos reais. A integração destes sistemas no fluxo de trabalho dos profissionais de saúde também requer cuidado, garantindo que a tecnologia complementa e não substitui o julgamento clínico.

## **2. Descrição do problema**

O câncer de pulmão é uma das principais causas de morte no mundo, representando um grande desafio para os sistemas de saúde devido à sua alta frequência e à dificuldade em diagnosticar precocemente. Detectar tumores pulmonares logo no início é essencial para aumentar as chances de um tratamento eficaz e melhorar a sobrevivência dos pacientes. No entanto, identificar esses tumores em exames de tomografia computadorizada (TC) é uma tarefa complexa, tanto do ponto de vista técnico quanto clínico.

Os radiologistas são os profissionais responsáveis por interpretar as imagens de TC para encontrar possíveis anomalias. Embora sejam altamente capacitados, esse processo depende muito da experiência e do julgamento individual de cada radiologista, o que pode resultar em variações nos diagnósticos. Além disso, a grande quantidade de imagens que precisam ser analisadas pode levar a erros ou omissões na detecção de tumores devido à alta carga de trabalho.

A natureza dos próprios tumores também complica a detecção. Eles podem ter diferentes tamanhos, formas e densidades, e muitas vezes estão em partes do pulmão que dificultam sua identificação. Nódulos pequenos podem passar despercebidos, enquanto sombras benignas podem ser confundidas com tumores malignos, resultando em biópsias desnecessárias e ansiedade para os pacientes.

Nesse contexto, o projeto tem como objetivo desenvolver e treinar uma rede neural convolucional (CNN) para detectar automaticamente tumores em exames de tomografia de pulmão. As CNNs são uma categoria de deep learning especialmente eficaz para tarefas de processamento de imagem, pois conseguem captar características espaciais hierárquicas. O modelo de CNN proposto será treinado com um amplo conjunto de dados de tomografias pulmonares, anotados por especialistas, para identificar com precisão a presença de tumores.

## **3. Metodologia**

Para a detecção eficiente de câncer em tomografias de tórax, adotamos uma abordagem baseada em redes neurais convolucionais (CNNs), que são amplamente reconhecidas por sua capacidade de analisar dados de imagem com alta precisão. Nossa metodologia compreende três etapas principais: treinamento otimizado do algoritmo com a biblioteca paralelizada TensorFlow e desenvolvimento e implantação de uma aplicação web hospedada na nuvem AWS.

## 4. Técnicas Implementadas

Para a implementação da rede neural convolucional (CNN) voltada para a detecção de tumores em exames de tomografia de pulmão, diversas técnicas e etapas foram adotadas para garantir a eficácia e precisão do modelo. Abaixo, descrevemos detalhadamente cada uma das técnicas utilizadas no desenvolvimento e treinamento do modelo.

1. Pré-processamento da Base de Dados O pré-processamento das imagens de tomografia foi uma etapa crucial para preparar os dados para o treinamento da CNN. As imagens passaram pelas seguintes transformações:

Redimensionamento: Todas as imagens foram redimensionadas para um tamanho uniforme compatível com a arquitetura da InceptionV3.

Normalização: Os valores dos pixels das imagens foram escalados para o intervalo  $[0, 1]$  utilizando a técnica de rescale  $(1.0/255.0)$ .

Aumento de Dados (Data Augmentation): Para aumentar a robustez do modelo e evitar overfitting, foram aplicadas diversas técnicas de aumento de dados, incluindo: Flip Horizontal: Aplicação de inversão horizontal aleatória. Preenchimento por Interpolação (Fill Mode): Utilização do modo 'nearest' para preencher pixels ausentes. Zoom: Aplicação de zoom aleatório de até 20%. Shear: Aplicação de cisalhamento aleatório de até 20%. Deslocamento Horizontal e Vertical: Deslocamentos aleatórios de até 20%. Rotação: Aplicação de rotações aleatórias de até 40 graus.

2. Arquitetura da Rede Neural Convolucional A arquitetura base utilizada para o treinamento foi a InceptionV3, uma rede neural convolucional profunda conhecida por sua eficiência e precisão em tarefas de classificação de imagens. A InceptionV3 foi escolhida devido à sua capacidade de capturar características complexas e hierárquicas nas imagens.

3. Customização do Modelo Base Para adaptar a InceptionV3 às necessidades específicas do projeto, foram realizadas as seguintes customizações:

Camadas Finais Personalizadas: As camadas finais da InceptionV3 foram ajustadas para incluir uma camada densa personalizada, adequada para a classificação binária (presença ou ausência de tumor). Função de Ativação: Utilização da função de ativação 'sigmoid' na camada de saída para obter a probabilidade de presença de tumor.

4. Ajustes de Hiperparâmetros O ajuste dos hiperparâmetros foi um passo essencial para otimizar o desempenho do modelo. Os hiperparâmetros ajustados incluíram:

Épocas (Epochs): O modelo foi treinado por 70 épocas. Taxa de Aprendizado (Learning Rate): Definida em 0.0001 para um ajuste fino dos pesos da rede. Técnicas de Data Augmentation: Conforme descrito anteriormente, foram utilizadas várias técnicas para aumentar a variedade dos dados de treinamento.

5. Treinamento Otimizado com TensorFlow Utilizamos TensorFlow, uma biblioteca de código aberto para aprendizado de máquina, para implementar e treinar nossa CNN. A escolha do TensorFlow nos permitiu aproveitar eficientemente o poder de processamento de hardware acelerado, como GPUs, para paralelizar o treinamento do modelo. Isso resultou em tempos de treinamento reduzidos e maior capacidade de lidar com conjuntos de dados complexos de imagens de tomografia.

## 5. Aplicação

O modelo gerado foi aproveitado em uma aplicação web com um frontend feito em JavaScript e um backend feito em Python, usando o framework Flask. Nesse serviço, o usuário acessa uma página web, na qual ele somente possui a opção de fazer um upload de imagem. Uma vez enviada a imagem, ela chega ao backend, o qual irá classificá-la como sendo uma imagem de um pulmão normal ou detentor de câncer. Sendo assim, o servidor envia essa resposta ao frontend, o qual irá exibí-la ao usuário.

# Cancer Detection App

Escolher arquivo 000130.png


Enviar Imagem

## Results:

Normal

**Figura 1.** Imagem do site após o usuário enviar uma imagem de uma tomografia de tórax com um pulmão livre de câncer

Ambos os códigos foram hospedados em servidores diferentes da AWS. No entanto, atualmente, os serviços mudam de IP em um período de quatro em quatro dias, além de serem reiniciados.

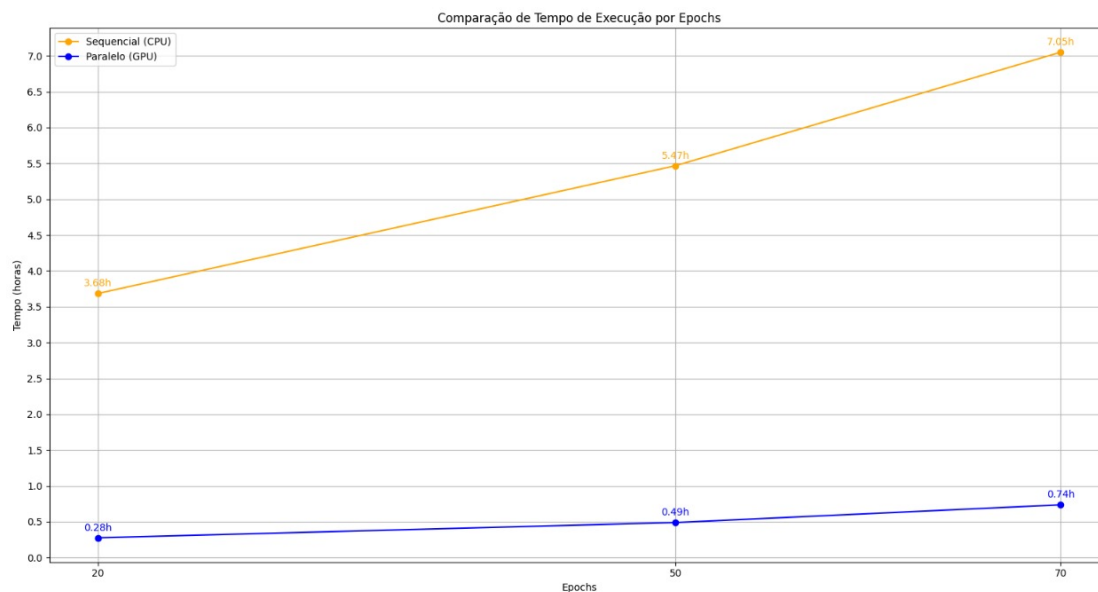


**Figura 2.** Imagem do site da AWS mostrando os servidores criados

## 6. Resultados Finais

A acurácia alcançada pelo modelo paralelizado atingiu 84%, indicando uma robustez considerável na capacidade de detecção de tumores pulmonares. Este resultado é demonstrado claramente no gráfico abaixo, que compara a taxa de acerto ao longo do treinamento entre as implementações em CPU e GPU:

A partir dos dados coletados, observamos que a utilização da GPU para paralelização do código resultou em tempos de treinamento significativamente reduzidos, permitindo processar volumes maiores de dados de tomografias de forma mais eficiente.



**Figura 3. Comparação do CPU x GPU**

Isso não apenas melhorou a eficácia do diagnóstico, mas também otimizou os recursos computacionais disponíveis, demonstrando o potencial das tecnologias de hardware acelerado na área de detecção médica assistida por inteligência artificial.

Destaca-se que o avanço das técnicas em processamento e análise de imagens e sua aplicação no diagnóstico prévio da doença tem um grande prospecto na área médica e na melhora da saúde humana e, tendo em vista o tempo de processamento elevado das técnicas de Deep Learning, o uso de métodos de paralelização e de computação distribuída tornam-se extremamente convenientes.

## 7. Trabalhos Relacionados

### 7.1. Demystifying parallel and distributed deep learning

Neste artigo, são exploradas abordagens para aprendizagem profunda paralela/distribuída em ambientes multi-core e distribuídos. Os autores analisam (empiricamente) a velocidade de treinamento de CNNs usando CPUs e GPUs tradicionais de núcleo único e fornecem recomendações práticas para reduzir o tempo de treinamento. Em um cenário distribuído, eles estudaram e analisaram algoritmos de atualização de peso síncronos e assíncronos (como Parallel SGD, ADMM e Downpour SGD) e propuseram o pior caso de custo de comunicação assintótica e tempo de computação de cada algoritmo. Embora muitos conceitos não tenham sido utilizados na versão final, o documento forneceu um impulso inicial para o desenvolvimento de aspectos de programação paralela e distribuída de aplicações.

### 7.2. Deep-learning framework to detect lung abnormality – A study with chest X-Ray and lung CT scan images

Este trabalho de pesquisa tem como objetivo propor uma estrutura de aprendizagem profunda (DL) para examinar pneumonia e câncer de pulmão. Este trabalho propõe duas

técnicas diferentes de aprendizagem profunda para avaliar o problema em consideração: (i) Um método inicial de aprendizagem profunda, denominado AlexNet Modificado (MAN), é proposto para classificar imagens de radiografia de tórax em categorias normais e pneumonia. Nas redes metropolitanas, a classificação é implementada usando máquinas de vetores de suporte (SVM) e o desempenho é comparado com Softmax.

### **7.3. Lungs cancer classification from CT images: An integrated design of contrast based classical features fusion and selection**

Neste trabalho, propôs-se um novo modelo do processo clássico de fusão de características baseado no alongamento de contraste para localização da classificação do câncer de pulmão. O método proposto inclui três etapas importantes: Primeiro, o contraste das imagens originais da TC é melhorado aproximando-se dos pesos máximos de intensidade da correção gama. Em segundo lugar, múltiplas texturas, pontos e características geométricas são extraídas de imagens de contraste, que são posteriormente submetidas à fusão serial com base na correlação canônica. Terceiro, valores zero e características negativas são substituídos por uma abordagem baseada em entropia seguida por NCA ponderada por seleção. A maioria dos recursos discriminativos são inseridos no classificador de conjunto para classificação final. A validação do método proposto é realizada em um conjunto de dados disponível publicamente: Lungs Data Science Bowl 2017 para atingir uma precisão máxima de 99,4 por cento.

## **Referências**

BEN-NUN, T.; HOEFLER, T. Demystifying parallel and distributed deep learning: An in-depth concurrency analysis. *ACM computing surveys*, v. 52, n. 4, p. 1–43, 2020

BHANDARY, A. et al. Deep-learning framework to detect lung abnormality – A study with chest X-Ray and lung CT scan images. *Pattern recognition letters*, v. 129, p. 271–278, 2020

KHAN, M. A. et al. Lungs cancer classification from CT images: An integrated design of contrast based classical features fusion and selection. *Pattern recognition letters*, v. 129, p. 77–85, 2020